

Signer — 用你自己的手勢，讓 avatar 替你開口

一個聽得到、卻說不出話的人，教 avatar 認得自己的手勢。從此 avatar 就是他的聲音。

GitHub github.com/Poyen-Chen/Signer_Avatar 作者 Poyen Chen 平台 Perxona Connect · Web

它是給誰用的

有一群人完全聽得懂你，卻沒辦法回答你：喉癌切除聲帶的人、漸凍人（ALS）、腦性麻痺、嚴重構音障礙。他們聽得到，只是沒有聲音。台灣的語言障礙者有數萬人，其中相當比例聽力正常——他們不是聾人，也多半不會手語。

現在他們的選擇是在手機上打字、按播放。很慢，而且把一段對話變成一次操作：對方低頭盯著螢幕、聽一個機器的聲音，而不是看著一個正在對他說話的人。

打字的人在別人眼裡是「在操作一台裝置」。Signer 讓他變成「在說話」。

我們做了什麼

STEP 1 · 教


做一個自己的手勢，打上它該說的話

任何動作都行——不是手語，是你自己發明的。錄三次，三十秒。

STEP 2 · 說

之後做那個手勢，avatar 就替你說出來

大聲說、有表情、有動作。打招呼會舉手，道謝會點頭。



Teach gestures 分頁：左邊是使用者教過的 23 個手勢與各自的錄製次數，右邊是攝影機畫面、動作強度量表與靈敏度。辨識失敗時 avatar 會開口請對方再做一次（右上角狀態列）。

辨識全程在瀏覽器裡跑，影像和骨架都不離開裝置；唯一送出去的是那句已經翻好的話，交給 Perxona avatar 唸出來。沒看清楚手勢時 avatar 會說「不好意思，我沒聽清楚，再一次」——對一個說不出話的人來說，avatar 開口請對方再一次，就是他自己在請對方再一次。

它解決了什麼問題

速度

打一句話要十幾秒；一個手勢不到一秒。對話的節奏才能跟得上。

門檻

手語要學三年。自己的手勢三十秒。不需要會任何語言，不需要別人也會。

被當成人看

對方看的是一張正在對他說話的臉，不是一支手機。人會對著臉說話——跟 avatar 講話，就是在跟它背後那個人講話。

隱私

攝影機畫面是別人家的對話。全部留在本機，這不是設定，是架構。

為什麼要有 AI avatar —— 拿掉它會怎樣

把 avatar 拿掉，剩下的是一個鍵盤加一個喇叭——那東西已經存在四十年了。avatar 是把「文字轉語音」變成「一個人」的關鍵，而且不是裝飾：

AVATAR 做的事	怎麼做到	拿掉會怎樣
身體跟語意一致	Perxona 動作庫帶 intent: 標籤 (greeting、apology、confusion...)，我們拿要說的句子去查，讓身體說的跟嘴巴說的是同一件事	一個沒有身體的聲音
一張讓對方看著的臉	對方對著 avatar 說話，就是對著它背後的人說話	對方低頭看手機
不出戲的補救	辨識失敗 → avatar 有禮貌地再問一次，這是人會做的事	一個沉默的錯誤
表情	句子的語意對應到 13 種情緒，道謝時是感激、道歉時是歉意	一張撲克臉

我們也玩出了 avatar 的一個新用法：平台的自動動作選擇在我們的帳號上不會回傳任何東西，所以 Signer 自己從動作目錄的 intent 標籤挑動作——這讓 avatar 的手勢跟句子意思對得上，而不是隨機亂動。

它獨特在哪裡

1. **不是手語辨識，是個人手勢辨識。** 市面上的手語 app 服務聾人，需要使用者會一套語言。Signer 服務的是聽得到但說不出來的人 —— 他們不會手語，也不該為了有聲音去學一門語言。任何動作對一句話，錄三次就好。
2. **輸出是一個人，不是一行字。** 語音辨識 app 把聲音變成字；我們把一個沒有聲音的人變成一個在說話的人。
3. **三十秒給自己一句新的話。** 現場 demo 會請評審給一句話，當場教會 avatar。這不是預錄好的橋段，是產品本身。
4. **隱私不是承諾，是架構。** MediaPipe 在瀏覽器裡跑，模型和 WASM 都從本機提供，斷網也能辨識。

技術

攝影機 → MediaPipe Holistic (WASM, 30 fps, 本機)

- 以身體為基準正規化的 128 維特徵 (手形 / 位置 / 移動)
- 動作能量自適應分段 (門檻是噪訊底線的倍數，不是絕對值)
- DTW 樣板比對，對照使用者自己錄的樣本 (雙重拒識：距離 + 邊際)
- 句子 → 語意 → 動作目錄 intent 查表
- `presenter.present(句子, {emotion}) + playMotion(動作)`

項目	選擇	理由
辨識	DTW 最近鄰	零訓練資料。比對的是使用者自己的動作，剛好符合「個人手勢」這個產品定位
特徵	手形 60 維 + 位置 3 維，各自除以維度平方根	否則手形會壓過位置 20 倍 —— 實測修正前「把手從胸口移到腰部」比「原地換手形」小四倍
分段門檻	噪訊底線的 2.0x 開始、1.65x 結束	絕對門檻換一台攝影機就失效；結束門檻若低於底線，開啟的分段永遠不會關
拒識	距離門檻 + 次選邊際	寧可沉默也不說錯 —— 錯話會用說不出話的人的名義大聲講出來
avatar	Perxona Connect <code><sv-presenter></code>	<code>present()</code> 負責語音與表情， <code>playMotion()</code> 獨立於語音佇列，短句也放得完整個手勢

如果它長成一個產品

每個使用者的手勢是自己的、存在自己的裝置上 —— 這代表它天生就是多租戶、天生就隱私。往下走的路很清楚：預訓練模型讓新使用者第一天就有幾百句可用；使用者錄的樣本在裝置上微調；語音接使用者自己的聲音複製，讓 avatar 用他原本的聲音說話 —— 對一個因病失去聲音的人，那才是完整的答案。

誠實的部分

- 辨識對錄的人準、對別人不準。實測跨人 42%。對個人手勢來說這是對的取舍 —— 沒有人需要做別人的動作 —— 但它不是通用的手語翻譯。
- 現在認得的詞彙就是使用者教過的。一個 250 詞的預訓練 ASL 模型 (Kaggle ISLR 冠軍、MIT 授權) 已經接上，但瀏覽器端唯一的 TFLite runtime 無法調整輸入張量大小。下一步是轉 ONNX。
- 手勢之間太像會混淆。我們有量測工具能找出哪幾對會撞 (例如數字 one—six 全部長太像)；解法是在錄的時候讓動作差異大一點。
- 33 隻 avatar 裡只有 6 隻帶 intent 標籤。選錯的話手勢不會對應語意，介面會直接說出來。